

**Московский государственный технический  
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 9

Выполнил:  
Ларкин Б. В.  
группа ИУ5-61Б

Проверил:  
Гапанюк Ю.Е.

Дата: 06.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

## **Задание:**

Номер варианта: **9**

Номер задачи: **2**

Номер набора данных, указанного в задаче: 1 ([https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load\\_iris.html#sklearn.datasets.load\\_iris](https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html#sklearn.datasets.load_iris))

Для студентов группы ИУ5-61Б - для пары произвольных колонок данных построить график "Диаграмма рассеяния".

### **Задача №2.**

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

## **1. Введение**

В рамках рубежного контроля была проведена работа с набором данных Iris Dataset. Целью работы являлось заполнение пропусков данных.

## **2. Описание исходных данных**

**Ирисы Фишера** — набор данных для задачи классификации, на примере которого Рональд Фишер в 1936 году продемонстрировал работу разработанного им метода дискриминантного анализа. Иногда его также называют ирисами Андерсона, так как данные были собраны американским ботаником Эдгаром Андерсоном. Этот набор данных стал классическим и часто используется в литературе для иллюстрации работы различных статистических алгоритмов

### 3. Ход выполнения:

#### Импорт библиотек

```
[1]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import *
from sklearn.impute import SimpleImputer, MissingIndicator
from sklearn.preprocessing import LabelEncoder
%matplotlib inline
sns.set(style='ticks')
```

#### Загрузка данных

```
[2]: iris = load_iris()
data = pd.DataFrame(data= np.c_[iris['data'], iris['target']],
                    columns= iris['feature_names'] + ['target'])
data['class'] = iris.target
data = data.drop('target', axis=1)
```

#### Основные характеристики датасета

```
[3]: # Первые 5 строк датасета
data.head()
```

```
[3]: .....
```

|   | sepal length (cm) | sepal width (cm) | petal length (cm) | petal width (cm) | class |
|---|-------------------|------------------|-------------------|------------------|-------|
| 0 | 5.1               | 3.5              | 1.4               | 0.2              | 0     |
| 1 | 4.9               | 3.0              | 1.4               | 0.2              | 0     |
| 2 | 4.7               | 3.2              | 1.3               | 0.2              | 0     |
| 3 | 4.6               | 3.1              | 1.5               | 0.2              | 0     |
| 4 | 5.0               | 3.6              | 1.4               | 0.2              | 0     |

,

```
[4]: # Размер датасета - 1025 строк, 14 колонок
data.shape
```

```
[4]: (150, 5)
```

```
[5]: data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   sepal length (cm)    150 non-null    float64
 1   sepal width (cm)     150 non-null    float64
 2   petal length (cm)    150 non-null    float64
 3   petal width (cm)     150 non-null    float64
 4   class                150 non-null    int32  
dtypes: float64(4), int32(1)
memory usage: 5.4 KB
```

```
[6]: total_count = data.shape[0]
```

```
[7]: data.isnull().sum() # 0 датасете отсутствуют пропуски
```

```
[7]: sepal length (cm)    0
sepal width (cm)      0
petal length (cm)     0
petal width (cm)      0
class                 0
dtype: int64
```

```
[8]: # Добавим искусственные пропуски для демонстрации
np.random.seed(42)
mask_quantitative = np.random.choice([True, False], size=len(data), p=[0.1, 0.9])
mask_categorical = np.random.choice([True, False], size=len(data), p=[0.1, 0.9])
```

```
[9]: # Создаем пропуски в количественном признаке (sepal length)
data.loc[mask_quantitative, 'sepal length (cm)'] = np.nan

# Создаем искусственный категориальный признак и добавляем в него пропуски
data['flower_color'] = np.random.choice(['red', 'blue', 'yellow'], size=len(data))
data.loc[mask_categorical, 'flower_color'] = np.nan
```

```
[10]: print("Данные с пропусками:")
print(data.isnull().sum())
```

```
Данные с пропусками:
sepal length (cm)    18
sepal width (cm)     0
petal length (cm)    0
petal width (cm)     0
class               0
flower_color        16
dtype: int64
```

```
[11]: # Определим уникальные значения для категориальных признаков
data['flower_color'].unique()
```

```
[11]: array(['red', 'blue', 'yellow', nan], dtype=object)
```

```
[12]: data['class'].unique()
```

```
[12]: array([0, 1, 2])
```

Целевой признак является бинарным; содержит значения 0, 1 и 2.

Обработка пустых значений

Категориальный признак

```
[13]: temp_null_count = data[data['flower_color'].isnull()].shape[0]
      dt = str(data['flower_color'].dtype)
      temp_perc = round((temp_null_count / total_count) * 100.0, 2)
      print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}'.format('flower_color', dt, temp_null_count, temp_perc))

Колонка flower_color. Тип данных object. Количество пустых значений 16, 10.67%.
```

```
[14]: # Обработка пропусков в категориальном признаке (мода)
      mode_rating = data['flower_color'].mode()[0]
      print(f'Мода для flower_color: {mode_rating}')
      data['flower_color'] = data['flower_color'].fillna(mode_rating)
```

Мода для flower\_color: red

```
[14]: .....
```

flower\_color

|     |        |
|-----|--------|
| 0   | red    |
| 1   | blue   |
| 2   | yellow |
| 3   | yellow |
| 4   | yellow |
| ... | ...    |
| 145 | yellow |
| 146 | red    |
| 147 | blue   |
| 148 | red    |
| 149 | red    |

150 rows × 1 columns

Количественный признак

```
[15]: temp_null_count = data[data['sepal length (cm)'].isnull()].shape[0]
      dt = str(data['sepal length (cm)'].dtype)
      temp_perc = round((temp_null_count / total_count) * 100.0, 2)
      print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}'.format('sepal length (cm)', dt, temp_null_count, temp_perc))

Колонка sepal length (cm). Тип данных float64. Количество пустых значений 18, 12.0%.
```

```
[16]: # Обработка пропусков в количественном признаке (медиана)
      quantitative_imputer = SimpleImputer(strategy='median')
      data['sepal length (cm)'] = quantitative_imputer.fit_transform(
          data[['sepal length (cm)']])
      data[['sepal length (cm)']]
```

```
[16]: .....
```

sepal length (cm)

|     |      |
|-----|------|
| 0   | 5.10 |
| 1   | 4.90 |
| 2   | 4.70 |
| 3   | 4.60 |
| 4   | 5.00 |
| ... | ...  |
| 145 | 5.75 |
| 146 | 6.30 |
| 147 | 6.50 |
| 148 | 5.75 |
| 149 | 5.90 |

150 rows × 1 columns

Повторная проверка пустых значений

```
[17]: print("\nДанные после обработки пропусков:")
      print(data.isnull().sum())
```

```
,Данные после обработки пропусков:
,sepal length (cm)    0
,sepal width (cm)     0
,petal length (cm)    0
,petal width (cm)     0
,class               0
,flower_color        0
,dtype: int64
```

Подготовка к использованию в модели

```
[18]: # Признаки для построения моделей
      features = ['sepal length (cm)', 'sepal width (cm)',
                  'petal length (cm)', 'petal width (cm)']
      iris_class = 'class'
```

```
[19]: data[features].describe()
```

```
[19]: .....
```

|       | sepal length (cm) | sepal width (cm) | petal length (cm) | petal width (cm) |
|-------|-------------------|------------------|-------------------|------------------|
| count | 150.000000        | 150.000000       | 150.000000        | 150.000000       |
| mean  | 5.822000          | 3.057333         | 3.758000          | 1.199333         |
| std   | 0.778147          | 0.435866         | 1.765298          | 0.762238         |
| min   | 4.300000          | 2.000000         | 1.000000          | 0.100000         |
| 25%   | 5.200000          | 2.800000         | 1.600000          | 0.300000         |
| 50%   | 5.750000          | 3.000000         | 4.350000          | 1.300000         |
| 75%   | 6.300000          | 3.300000         | 5.100000          | 1.800000         |
| max   | 7.900000          | 4.400000         | 6.900000          | 2.500000         |

,


```
[20]: data[iris_class].unique()
```

```
[20]: array([0, 1, 2])
```

## Диаграммы рассеяния

Позволяют построить распределение двух колонок данных и визуально обнаружить наличие зависимости. Не предполагается, что значения упорядочены (например, по времени).

```
[22]: fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax,x='sepal length (cm)', y='petal length (cm)', data=data, hue='class')
[22]: <Axes: xlabel='sepal length (cm)', ylabel='petal length (cm)'>
```



## 4. Ответы на вопросы

### Способы обработки пропусков

Для качественного и количественного признаков была использована методика импутации данных - "внедрения значений".

Процесс импутации - это замещение ошибочных, противоречивых и отсутствующих ответов в процессе редактирования данных другими ответами - значениями показателей. Стратегия проведения импутации определяется заранее при подготовке методологии проведения статистического наблюдения.

Для количественного признака (sepal length) использована стратегия медианы (strategy='median').

### Причины выбора:

1. Медиана устойчива к выбросам
2. Сохраняет распределение признака
3. Не искажает статистические свойства данных

Для категориального признака (flower\_color) использован метод замены пустых значений рейтингом моды. Как видим, мода для цвета растений оказалась "red".

### Причины выбора:

1. Простота реализации

## **Признаки для построения моделей**

### **Выбранные признаки (features):**

- sepal length (cm) - количественный;
- sepal width (cm) - количественный;
- petal length (cm) - количественный;
- petal width (cm) - количественный;

### **Целевой признак:**

- class\_enc - категориальный, приведенный к норм. виду.

### **Все оригинальные признаки из датасета Iris:**

Эти признаки исторически показывают хорошую разделимость классов:

1. Содержат информацию о размерах цветка, что напрямую связано с видом ириса
2. Имеют высокую корреляцию с целевой переменной

Искусственный категориальный признак (flower\_color) добавлен для демонстрации работы с разными типами данных, его использование в моделях нельзя назвать целесообразным.

Исключены:

1. Необработанные категориальные признаки (требуют кодирования)
2. Признаки с низкой вариативностью
3. Признаки с высокой корреляцией между собой

## **5. Выводы**

В ходе работы были успешно выполнены задачи по обработке данных, заполнению пропусков, кодированию категориальных данных и визуализации диаграмм рассеяния.