

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 9

Выполнил:
Ларкин Б. В.
группа ИУ5-61Б

Проверил:
Гапанюк Ю.Е.

Дата: 06.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Задание:

Номер варианта: **9**

Номер задачи: **2**

Номер набора данных, указанного в задаче: 1 (https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html#sklearn.datasets.load_iris)

Для студентов группы ИУ5-61Б - для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Задача №2.

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

1. Введение

В рамках рубежного контроля была проведена работа с набором данных Iris Dataset. Целью работы являлось заполнение пропусков данных.

2. Описание исходных данных

Ирисы Фишера — набор данных для задачи классификации, на примере которого Рональд Фишер в 1936 году продемонстрировал работу разработанного им метода дискриминантного анализа. Иногда его также называют ирисами Андерсона, так как данные были собраны американским ботаником Эдгаром Андерсоном. Этот набор данных стал классическим и часто используется в литературе для иллюстрации работы различных статистических алгоритмов

3. Ход выполнения:

Импорт библиотек

```
[1]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import *
from sklearn.impute import SimpleImputer, MissingIndicator
from sklearn.preprocessing import LabelEncoder
%matplotlib inline
sns.set(style='ticks')
```

Загрузка данных

```
[2]: iris = load_iris()
data = pd.DataFrame(data= np.c_[iris['data'], iris['target']],
                    columns= iris['feature_names'] + ['target'])
data['class'] = iris.target
data = data.drop('target', axis=1)
```

Основные характеристики датасета

```
[3]: # Первые 5 строк датасета
data.head()
```

```
[3]: .....
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	class
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.2	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0

,

```
[4]: # Размер датасета - 1025 строк, 14 колонок
data.shape
```

```
[4]: (150, 5)
```

```
[5]: data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   sepal length (cm)    150 non-null   float64
 1   sepal width (cm)     150 non-null   float64
 2   petal length (cm)    150 non-null   float64
 3   petal width (cm)     150 non-null   float64
 4   class                150 non-null   int32  
dtypes: float64(4), int32(1)
memory usage: 5.4 KB
```

```
[6]: total_count = data.shape[0]
```

```
[7]: data.isnull().sum() # 0 датасете отсутствуют пропуски
```

```
[7]: sepal length (cm)    0
sepal width (cm)      0
petal length (cm)     0
petal width (cm)      0
class                 0
dtype: int64
```

```
[8]: # Добавим искусственные пропуски для демонстрации
np.random.seed(42)
mask_quantitative = np.random.choice([True, False], size=len(data), p=[0.1, 0.9])
mask_categorical = np.random.choice([True, False], size=len(data), p=[0.1, 0.9])
```

```
[9]: # Создаем пропуски в количественном признаке (sepal length)
data.loc[mask_quantitative, 'sepal length (cm)'] = np.nan

# Создаем искусственный категориальный признак и добавляем в него пропуски
data['flower_color'] = np.random.choice(['red', 'blue', 'yellow'], size=len(data))
data.loc[mask_categorical, 'flower_color'] = np.nan
```

```
[10]: print("Данные с пропусками:")
print(data.isnull().sum())
```

```
Данные с пропусками:
sepal length (cm)    18
sepal width (cm)     0
petal length (cm)    0
petal width (cm)     0
class               0
flower_color        16
dtype: int64
```

```
[11]: # Определим уникальные значения для категориальных признаков
data['flower_color'].unique()
```

```
[11]: array(['red', 'blue', 'yellow', nan], dtype=object)
```

```
[12]: data['class'].unique()
```

```
[12]: array([0, 1, 2])
```

Целевой признак является бинарным; содержит значения 0, 1 и 2.

Обработка пустых значений

Категориальный признак

```
[13]: temp_null_count = data[data['flower_color'].isnull()].shape[0]
      dt = str(data['flower_color'].dtype)
      temp_perc = round((temp_null_count / total_count) * 100.0, 2)
      print('Колонка {}. Тип данных {}. Количество пустых значений {}, {:.1f}'.format('flower_color', dt, temp_null_count, temp_perc))

Колонка flower_color. Тип данных object. Количество пустых значений 16, 10.67%.
```

```
[14]: # Обработка пропусков в категориальном признаке (наиболее частый класс)
      categorical_imputer = SimpleImputer(strategy='most_frequent')
      data['flower_color'] = categorical_imputer.fit_transform(
          data[['flower_color']].flatten()

      data[['flower_color']]
```

```
[14]: .....
```

flower_color	
0	red
1	blue
2	yellow
3	yellow
4	yellow
...	...
145	yellow
146	red
147	blue
148	red
149	red

150 rows x 1 columns

Количественный признак

```
[15]: temp_null_count = data[data['sepal length (cm)'].isnull()].shape[0]
      dt = str(data['sepal length (cm)'].dtype)
      temp_perc = round((temp_null_count / total_count) * 100.0, 2)
      print('Колонка {}. Тип данных {}. Количество пустых значений {}, {:.1f}'.format('sepal length (cm)', dt, temp_null_count, temp_perc))

Колонка sepal length (cm). Тип данных float64. Количество пустых значений 18, 12.0%.
```

```
[16]: # Обработка пропусков в количественном признаке (медиана)
      quantitative_imputer = SimpleImputer(strategy='median')
      data['sepal length (cm)'] = quantitative_imputer.fit_transform(
          data[['sepal length (cm)']]

      data[['sepal length (cm)']]
```

```
[16]: .....
```

sepal length (cm)	
0	5.10
1	4.90
2	4.70
3	4.60
4	5.00
...	...
145	5.75
146	6.30
147	6.50
148	5.75
149	5.90

150 rows x 1 columns

Повторная проверка пустых значений

```
[17]: print("\nДанные после обработки пропусков:")
      print(data.isnull().sum())
```

Данные после обработки пропусков:
,sepal length (cm) 0
,sepal width (cm) 0
,petal length (cm) 0
,petal width (cm) 0
,class 0
,flower_color 0
,dtype: int64

Подготовка к использованию в модели

```
[18]: # Признаки для построения моделей
      features = ['sepal length (cm)', 'sepal width (cm)',
                  'petal length (cm)', 'petal width (cm)'
                  ]
      iris_class = 'class'
```

```
[19]: data[features].describe()
```

```
[19]: .....
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
count	150.000000	150.000000	150.000000	150.000000
mean	5.822000	3.057333	3.758000	1.199333
std	0.778147	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.200000	2.800000	1.600000	0.300000
50%	5.750000	3.000000	4.350000	1.300000
75%	6.300000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

,


```
[20]: data[iris_class].unique()
```

```
[20]: array([0, 1, 2])
```


Диаграммы рассеивания

Позволяют построить распределение двух колонок данных и визуально обнаружить наличие зависимости. Не предполагается, что значения упорядочены (например, по времени).

```
[21]: fig, ax = plt.subplots(figsize=(10,10))
      sns.scatterplot(ax=ax, x='sepal length (cm)', y='sepal width (cm)', data=data)
```




```
[21]: <Axes: xlabel='sepal length (cm)', ylabel='sepal width (cm)'>
```



```
[22]: fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax,x='sepal length (cm)', y='petal length (cm)', data=data, hue='class')
```

```
[22]: <Axes: xlabel='sepal length (cm)', ylabel='petal length (cm)'>
```



4. Ответы на вопросы

Способы обработки пропусков

Для качественного и количественного признаков была использована методика импутации данных - "внедрения значений".

Процесс импутации - это замещение ошибочных, противоречивых и отсутствующих ответов в процессе редактирования данных другими ответами - значениями показателей. Стратегия проведения импутации определяется заранее при подготовке методологии проведения статистического наблюдения.

Для количественного признака (sepal length) использована стратегия медианы (strategy='median').

Причины выбора:

1. Медиана устойчива к выбросам
2. Сохраняет распределение признака
3. Не искажает статистические свойства данных

Для категориального признака (`flower_color`) использована стратегия наиболее частого значения (`strategy='most_frequent'`).

Причины выбора:

1. Простота реализации
2. Минимальное искажение данных

Признаки для построения моделей

Выбранные признаки (features):

- `sepal length (cm)` - количественный;
- `sepal width (cm)` - количественный;
- `petal length (cm)` - количественный;
- `petal width (cm)` - количественный;

Целевой признак:

- `class_enc` - категориальный, приведенный к норм. виду.

Все оригинальные признаки из датасета Iris:

Эти признаки исторически показывают хорошую разделимость классов:

1. Содержат информацию о размерах цветка, что напрямую связано с видом ириса
2. Имеют высокую корреляцию с целевой переменной

Искусственный категориальный признак (`flower_color`) добавлен для демонстрации работы с разными типами данных, его использование в моделях нельзя назвать целесообразным.

Исключены:

1. Необработанные категориальные признаки (требуют кодирования)
2. Признаки с низкой вариативностью
3. Признаки с высокой корреляцией между собой

5. Выводы

В ходе работы были успешно выполнены задачи по обработке данных, заполнению пропусков, кодированию категориальных данных и визуализации диаграмм распределения.